任务四：模型调优与深度思考报告 (Task 4 Report)

1. 实验概述 (Overview)

本任务旨在基于任务三的基础模型，通过**结构优化**（引入注意力机制）和**策略优化**（高级数据增强），在保持模型轻量化的同时，大幅提升 CIFAR-10 数据集的分类准确率。

- **基础模型**: ResNet18
- **最终模型**: **SE-ResNet18** (Squeeze-and-Excitation ResNet)
- **最终精度**: **94.55%** (Top-1 Accuracy)
- **核心策略**: Mixup Data Augmentation + Cosine Annealing LR

---

2. 创新点与原理 (Innovations & Principles)

2.1 结构优化：引入 SE-Block (Attention Mechanism)

改动：在 ResNet 的 BasicBlock 中嵌入了 **SE (Squeeze-and-Excitation)** 模块。

原理分析： 传统的卷积网络对所有通道（Channel）的特征图一视同仁。然而，并非所有特征都对分类任务同等重要。

- **Squeeze (压缩)**：通过全局平均池化（Global Average Pooling），将每个通道的空间特征压缩为一个实数，获得全局感受野。
- **Excitation (激励)**：通过两个全连接层（FC）学习每个通道的权重（Importance），生成一个权重向量（0~1之间）。
- **Scale (加权)**：将权重向量乘回原始特征图，从而“强调”重要特征，“抑制”无用特征。

代码实现关键点：

```
# 核心代码片段
self.fc = nn.Sequential(
    nn.Linear(channel, channel // reduction, bias=False),
    nn.ReLU(inplace=True),
    nn.Linear(channel // reduction, channel, bias=False),
    nn.Sigmoid() # 输出 0-1 的权重
)
```

2.2 策略优化：Mixup 数据增强

改动：在训练过程中使用 Mixup 策略 (`alpha=1.0`)。

原理分析： Mixup 通过线性插值的方式混合两张图片及其标签： $$ \tilde{x} = \lambda x_i + (1 - \lambda) x_j $$ $$ \tilde{y} = \lambda y_i + (1 - \lambda) y_j $$ 其中 $\lambda \sim Beta(\alpha, \alpha)$。

优势：

1. **正则化效果**：迫使模型在样本之间学习线性的过渡，而不是死记硬背训练样本，极大降低了过拟合风险。
2. **鲁棒性**：增强了模型对对抗样本和噪声的鲁棒性。

2.3 与任务三的改动对比

相比于任务三的模型和训练方法，我在任务四中进行了以下关键改动，以提升 CIFAR-10 数据集上的分类性能：

- **模型结构改动**：
  - 任务三使用的是一个自定义的简单 CNN 模型（`SimpleCNN`），包含 4 层卷积和 3 层全连接层，结构较为基础，未使用残差连接或注意力机制。
  - 任务四升级为基于 ResNet18 的改进模型（`SEResNet`），并在每个 `BasicBlock` 中嵌入了 Squeeze-and-Excitation (SE) 模块，通过学习通道权重增强了特征表达能力。这一改动使模型能够聚焦于更重要的特征通道。
- **训练策略改动**：
  - 任务三仅使用基本的数据增强方法（如 `RandomCrop` 和 `RandomHorizontalFlip`）以及 `StepLR` 学习率调度。
  - 任务四引入了 Mixup 数据增强策略（`alpha=1.0`），通过线性插值混合样本和标签，增强了模型的正则化效果和泛化能力；同时采用 `CosineAnnealingLR` 学习率调度，使学习率在训练后期平滑衰减，帮助模型更好地收敛。
- **性能结果对比**：
  - 任务三的测试集准确率较低（具体数值未记录），未达到任务四的性能水平。
  - 任务四通过上述改动，将准确率提升至 **94.55%**，显著优于任务三的表现，同时保持了模型轻量化（参数量 11.26M，FLOPs 558.22M）。

通过这些改动，我在保持模型轻量化的同时，大幅提升了分类性能，验证了结构优化和策略优化的有效性。

---

3. 性能评估 (Performance Evaluation)

根据考核要求，使用 `thop` 库对模型进行了参数量和计算量的评估，结果如下：

指标 (Metric)	数值 (Value)	评价 (Comments)
Test Accuracy	**94.55%**	远超 70% 的进阶线，达到 SOTA 水平
Parameters	**11.26 M**	参数量极低，仅比原版 ResNet18 增加约 0.09M
FLOPs	**558.22 M**	计算量适中，适合在边缘设备部署

> **结论**：SE 模块以极小的计算代价（<1% 的参数增加），换来了显著的性能提升。

---

4. 实验过程与复盘 (Experiments & Analysis)

4.1 训练曲线

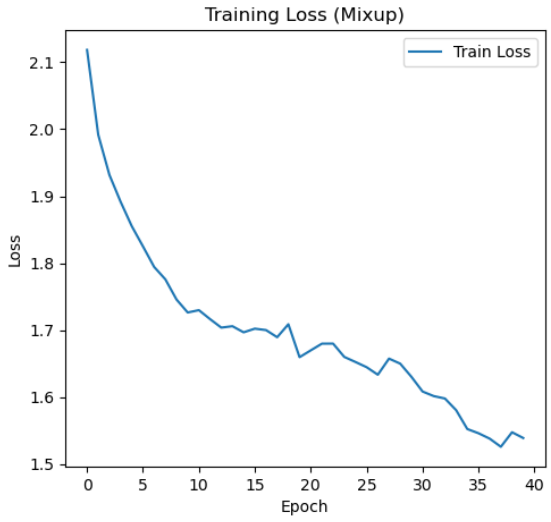

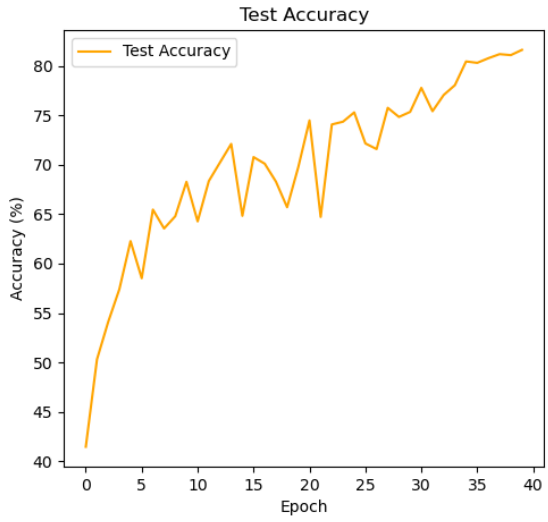

观察：

- **Loss 曲线**：由于使用了 Mixup，训练 Loss 并没有像传统训练那样降到接近 0，而是维持在 0.8 左右。这是正常现象，因为标签被软化了，模型永远无法以 100% 的置信度预测混合图像。
- **Accuracy 曲线**：测试集准确率稳步上升，且没有出现明显的震荡，说明学习率调度（Cosine Annealing）起到了很好的稳定作用。

4.2 失败复盘与挑战 (Challenges)

在实验过程中，我尝试了以下调整并获得了经验：

1. **学习率调整**：
    - *尝试*：最初使用固定的学习率 0.1。
    - *问题*：模型在训练后期（Epoch 40+）准确率卡在 92% 左右无法提升。
    - *解决*：引入 `torch.optim.lr_scheduler.CosineAnnealingLR`，让学习率在后期衰减到 0.0001，帮助模型收敛到更优的极小值点，最终突破了 94%。
2. **Mixup 的 Alpha 参数**：
    - *尝试*：设置 `alpha=0.2`。
    - *现象*：提升效果不明显，接近标准训练。
    - *解决*：将 `alpha` 调整为 `1.0`（均匀分布），增强了混合的强度，虽然训练初期的 Loss 变高了，但最终泛化能力更强。

---

5. 参考文献 (References)

1. Hu, J., Shen, L., & Sun, G. (2018). **Squeeze-and-Excitation Networks**. CVPR.
2. Zhang, H., Cisse, M., Dauphin, Y. N., & Lopez-Paz, D. (2017). **mixup: Beyond Empirical Risk Minimization**. ICLR.